

القسم الأول: اختيار من متعدد (20 سؤال)

الهدف الأساسي من NLP هو:

أ) تحليل الصور

ب) فهم اللغة البشرية

ج) تحسين الشبكات

د) ضغط البيانات

الحل: ب) فهم اللغة البشرية

Tokenization تعني:

أ) ترجمة النص

ب) تقسيم النص

ج) ضغط النص

د) حذف الكلمات

الحل: ب) تقسيم النص

Stop Words هي:

أ) كلمات نادرة

ب) كلمات شائعة قليلة القيمة

ج) كلمات تقنية

د) كلمات طويلة

الحل: ب) كلمات شائعة قليلة القيمة

TF-IDF يستخدم لـ:

أ) الترجمة

ب) تمثيل النص

ج) تصنيف الصور

د) ضغط البيانات

الحل: ب) تمثيل النص

Bag of Words:

أ) يحافظ على ترتيب الكلمات

ب) يهمل الترتيب

ج) يستخدم الشبكات العصبية

د) يعتمد على السياق

الحل: ب) يهمل الترتيب

أي نموذج يعتمد على السياق؟

أ) TF-IDF

ب) Bag of Words

ج) BERT

د) Count Vector

الحل: ج) BERT

Lemmatization:

أ) تقطيع النص

ب) تحويل الكلمة لأصلها

ج) حذف الكلمات

د) ضغط النص

الحل: ب) تحويل الكلمة لأصلها

Word2Vec ينتج:

أ) صور

ب) متجهات

ج) جمل

د) قواعد

الحل: ب) متجهات

أي خوارزمية مناسبة لتصنيف النص؟

أ) KNN

ب) Naive Bayes

ج) Decision Tree

(د) جميع ما سبق

الحل: (د) جميع ما سبق

NER تعني:

أ) تحليل المشاعر

ب) التعرف على الكيانات

ج) الترجمة

د) تصنيف النص

الحل: (ب) التعرف على الكيانات

Overfitting يعني:

أ) نموذج ضعيف

ب) نموذج يحفظ البيانات

ج) نموذج سريع

د) نموذج بسيط

الحل: (ب) نموذج يحفظ البيانات

Underfitting يعني:

أ) نموذج بسيط جدًا

ب) نموذج معقد

ج) نموذج دقيق

د) نموذج سريع

الحل: (أ) نموذج بسيط جدًا

Embedding هو:

أ) صورة

ب) تمثيل رقمي للكلمات

ج) نص

د) خوارزمية

الحل: (ب) تمثيل رقمي للكلمات

Language Model هدفه:

أ) الترجمة

ب) توقع الكلمة التالية

ج) ضغط النص

د) حذف الكلمات

الحل: ب) توقع الكلمة التالية

Transformer يعتمد على:

أ) CNN

ب) RNN

ج) Attention

د) KNN

الحل: ج) Attention

Attention يساعد في:

أ) حذف الكلمات

ب) التركيز على الكلمات المهمة

ج) ضغط النص

د) تحويل النص

الحل: ب) التركيز على الكلمات المهمة

POS Tagging:

أ) ترجمة

ب) تحديد نوع الكلمة

ج) حذف الكلمات

د) تحليل الصور

الحل: ب) تحديد نوع الكلمة

أي مما يلي Unsupervised؟

أ) Classification

ب) Clustering

ج) Regression

Decision Tree (د)

الحل: ب) Clustering

Cosine Similarity تستخدم لـ:

أ) الترجمة

ب) قياس التشابه

ج) تصنيف الصور

د) ضغط النص

الحل: ب) قياس التشابه

GPT هو:

أ) نموذج لغة

ب) خوارزمية تصنيف

ج) قاعدة بيانات

د) نظام تشغيل

الحل: أ) نموذج لغة

القسم الثاني: أسئلة نظرية (15 سؤال)

1. اشرح مفهوم Tokenization مع مثال

تقسيم النص إلى وحدات صغيرة (مثل الكلمات)،

مثال: "تعلم البرمجة" تصبح ["تعلم", "البرمجة"].

2. ما الفرق بين Stemming و Lemmatization؟

الـ Stemming يقص الزوائد عشوائياً، والـ Lemmatization يعيد الكلمة لأصلها اللغوي الصحيح.

3. ما هو Bag of Words؟ وما عيوبه؟

الحل:

تمثيل النص بعدد تكرار الكلمات؛

وعيوبه أنه يتجاهل ترتيب الكلمات والمعنى السياقي.

4. اشرح TF-IDF وكيف يعمل.

الحل:

تقنية تقيس أهمية الكلمة؛

تزيد قيمتها إذا كانت نادرة في النصوص الكلية ومتكررة في النص الحالي.

5. ما هي Word Embeddings؟

الحل:

تمثيل الكلمات كأرقام (متجهات) بحيث تتقارب الكلمات المتشابهة في المعنى مكانياً.

6. ما الفرق بين Word2Vec و GloVe؟

الحل:

Word2Vec يعتمد على التنبؤ بالسياق،

و GloVe يعتمد على إحصائيات ظهور الكلمات معاً عالمياً.

7. ما هي التحديات في اللغة العربية؟

الحل:

كثرة الاشتقاقات الصرفية، اختلاف اللهجات، وغياب التشكيل الذي يسبب غموض المعنى.

8. اشرح مفهوم Language Modeling.

الحل:

هو بناء نموذج رياضي يتوقع الكلمة التالية في الجملة بناءً على ما سبقها.

9. ما هو Attention Mechanism؟

الحل:

آلية تجعل النموذج يركز على الكلمات الأكثر أهمية لإنتاج المخرج المطلوب.

10. ما الفرق بين RNN و Transformer؟

الحل:

الـ RNN يعالج الكلمات واحدة تلو الأخرى (بطيء)،

والـ Transformer يعالج الجملة كاملة معاً.

11. ما هو NER مع مثال؟

الحل:

التعرف على الكيانات؛

مثال: استخراج "اليمن" كاسم مكان في النص.

12. اشرح POS Tagging.

الحل:

عملية تحديد النوع النحوي لكل كلمة في الجملة.

13. ما هو Sentiment Analysis؟

الحل:

تحليل المشاعر لتحديد نبرة النص إذا كانت إيجابية أو سلبية أو محايدة.

14. ما هو Overfitting وكيف تعالجه؟

الحل:

حفظ البيانات بدقة وفشل الاختبار؛

ويعالج بزيادة البيانات أو ال Dropout.

15. ما الفرق بين Supervised و Unsupervised في NLP؟

الحل:

ال Supervised يعتمد على إجابات جاهزة،

وال Unsupervised يحلل البيانات بدون تسميات.

القسم الثالث: أسئلة عملية وتحليلية

1. قم بعمل Tokenization للجملة:

الحل:

["الذكاء", "الاصطناعي", "يغير", "العالم"]

2. احذف Stop Words من الجملة:

الحل:

["أريد", "أتعلم", "معالجة", "اللغات", "الطبيعية"]

(حذفنا "أنا" و "أن")

3. إذا ظهرت كلمة في 50 مستند من أصل 1000: احسب IDF تقريباً

الحل:

1.3 (بناءً على المعادلة $\log(1000/50)$)

4. احسب Cosine Similarity بين متجهين بسيطين (أعط مثال).

المثال: المتجه الأول [0, 1] والمتجه الثاني [1, 0].

الإجابة: النتيجة هي 1، لأن المتجهين متطابقين تماماً والزاوية بينهما صفر.

5. لديك بيانات نصية: كيف تحوّلها إلى أرقام؟

الإجابة: باستخدام تقنيات مثل One-Hot Encoding، أو TF-IDF، أو نماذج Word Embeddings (مثل Word2Vec).

6. صمّم Pipeline لمعالجة النصوص.

الإجابة: (تنظيف النص -> Tokenization -> حذف كلمات التوقف -> Lemmatization -> تحويل لمتجهات -> تدريب النموذج).

7. لديك Dataset صغير: أي نموذج تختار ولماذا؟

الإجابة: أختار Naive Bayes؛ لأنه بسيط، سريع، ولا يحتاج لبيانات ضخمة ليعطي نتائج دقيقة.

8. لديك Dataset كبير: ما النموذج الأفضل؟

الإجابة: أختار نماذج الـ Transformer (مثل BERT)؛ لقدرتها العالية على تعلم الأنماط المعقدة من البيانات الضخمة.

9. كيف تحسن دقة نموذج تصنيف نصوص؟

الإجابة: بزيادة حجم البيانات، تحسين جودة التنظيف، أو عمل Fine-tuning لنماذج لغوية مدربة مسبقاً.

10. كيف تتعامل مع النصوص العربية؟

الإجابة: باستخدام مكتبات متخصصة مثل (Camel Tools) للتعامل مع الجذور والضمائر المتصلة والتشكيل.

11. صمّم نظام Sentiment Analysis.

الإجابة: (جمع بيانات -> تنظيف -> تحويل لمتجهات -> تدريب خوارزمية Logistic Regression للتصنيف).

12. لديك مشكلة Overfitting: اقترح 3 حلول.

الإجابة: 1. استخدام Dropout. 2. زيادة كمية البيانات. 3. التوقف المبكر (Early Stopping) أثناء التدريب.

13. قارن بين: Naive Bayes و Logistic Regression.

الإجابة: Naive Bayes أسرع وأبسط، بينما Logistic Regression أدق في فهم العلاقات المعقدة بين الكلمات.

14. لديك نصوص غير نظيفة: كيف تنظفها؟

الإجابة: إزالة الروابط والرموز، حذف المسافات الزائدة، وتوحيد رسم الحروف (مثل أ، إ، آ إلى ا).

15. صمّم مشروع NLP كامل (من البداية للنهاية).

[1] تحديد المشكلة ونطاق المشروع

Problem Definition & Scoping

هذه هي نقطة البداية، حيث نحدد هدف المشروع بوضوح:

نوع المهمة (Task Type):

هل هي تصنيف نصوص (Classification)؟

تلخيص (Summarization)؟

أو ترجمة (Translation)؟

تحديد المقاييس (Success Metrics):

مثل Accuracy أو F1-Score لقياس أداء النموذج.

[2] جمع البيانات

Data Acquisition (Sourcing)

في هذه المرحلة نقوم بتجميع البيانات التي سيتعلم منها النموذج:

المصادر (Sources):

Web Scraping

قواعد بيانات SQL

مجموعات جاهزة مثل HuggingFace

تجهيز البيانات (Data Labeling):

إضافة الوسوم (Tags) إذا كان التعلم Supervised.

[3] المعالجة الأولية للنصوص

Text Preprocessing

تحويل النص الخام إلى بيانات نظيفة قابلة للمعالجة:

التنظيف (Cleaning):

إزالة الروابط، الرموز التعبيرية، وعلامات الترقيم.

التقطيع (Tokenization):

تقسيم الجمل إلى كلمات أو أجزاء.

المعالجة اللغوية (Linguistic Processing):

Lemmatization (إرجاع الكلمة لأصلها)

إزالة Stop Words

[4] تمثيل البيانات (هندسة الميزات)

Text Representation (Vectorization)

تحويل النص إلى أرقام:

الطرق التقليدية:

TF-IDF

Bag of Words

الطرق الحديثة:

Word Embeddings

مثل Word2Vec و FastText

[5] بناء وتدريب النموذج

Model Building & Training

اختيار النموذج المناسب وتدريبه:

اختيار الخوارزمية (Algorithm Selection):

نماذج تقليدية: Naive Bayes

نماذج حديثة: Transformers مثل BERT و GPT

عملية التدريب (Training Loop):

إدخال البيانات للنموذج ليتعلم الأنماط.

ضبط المعلمات (Hyperparameter Tuning):

تحسين إعدادات النموذج للحصول على أفضل أداء.

[6] التقييم والاختبار

Evaluation & Testing

التأكد من جودة النموذج:

اختبار البيانات (Test Set):

اختبار النموذج على بيانات جديدة.

تحليل الأخطاء (Error Analysis):

فهم الأخطاء مثل:

السخرية

اللهجات

[7] النشر والتشغيل

Deployment & Integration

تحويل النموذج إلى منتج عملي:

بناء API:

باستخدام FastAPI أو Flask

الحاوية (Containerization):

باستخدام Docker

واجهة المستخدم (UI):

مثل Streamlit أو موقع ويب

[8] المراقبة والتحديث

Monitoring & Maintenance

استمرار تحسين النظام بعد النشر:

Data Drift:

مراقبة تغير البيانات مع الزمن

Feedback Loop:

استخدام ملاحظات المستخدمين لتحسين النموذج

القسم الرابع: اختيار من متعدد

1. ما هو Byte Pair Encoding (BPE)؟

أ) خوارزمية ضغط نصوص

ب) طريقة Tokenization

ج) نموذج لغة

د) خوارزمية تصنيف

الحل:

ب) طريقة Tokenization.

2. Subword Tokenization تستخدم لـ:

أ) حذف الكلمات

ب) التعامل مع الكلمات النادرة

ج) ترجمة النص

د) ضغط البيانات

الحل:

ب) التعامل مع الكلمات النادرة.

3. ما هو n-gram؟

أ) نموذج عميق

ب) تسلسل من n كلمات

ج) خوارزمية

د) قاعدة بيانات

الحل:

ب) تسلسل من n كلمات.

4. Bigram يعني:

أ) كلمة واحدة

ب) كلمتين

ج) ثلاث كلمات

د) أربع كلمات

الحل:

ب) كلمتين.

5. Trigram يعني:

أ) كلمتين

ب) ثلاث كلمات

ج) أربع كلمات

د) خمس كلمات

الحل:

ب) ثلاث كلمات.

6. Perplexity تستخدم لـ:

أ) قياس جودة النموذج اللغوي

ب) ضغط النص

ج) حذف الكلمات

د) تصنيف الصور

الحل:

أ) قياس جودة النموذج اللغوي.

7. BLEU Score يستخدم في:

أ) تصنيف النص

ب) الترجمة الآلية

ج) تحليل المشاعر

د) clustering

الحل:

ب) الترجمة الآلية.

8. ROUGE يستخدم في:

أ) الترجمة

ب) التلخيص

ج) التصنيف

(د) التعلم العميق

الحل:

(ب) التلخيص.

9. Seq2Seq Model يستخدم في:

(أ) التصنيف

(ب) الترجمة

(ج) clustering

(د) PCA

الحل:

(ب) الترجمة.

10. Encoder يقوم بـ:

(أ) توليد النص

(ب) تمثيل الإدخال

(ج) حذف الكلمات

(د) ضغط الصور

الحل:

(ب) تمثيل الإدخال.

11. Decoder يقوم بـ:

(أ) تحليل الصور

(ب) توليد النص

(ج) حذف الكلمات

(د) تصنيف البيانات

الحل:

(ب) توليد النص.

12. Masked Language Model:

(أ) يتوقع الكلمة المحذوفة

(ب) يترجم النص

(ج) يصنف النص

(د) يضغط البيانات

الحل:

(أ) يتوقع الكلمة المحذوفة.

13. Autoregressive Model:

(أ) يتوقع كل الكلمات دفعة واحدة

(ب) يتوقع الكلمة التالية

(ج) لا يستخدم سياق

(د) نموذج ثابت

الحل:

(ب) يتوقع الكلمة التالية.

14. Transformer يتكون من:

(أ) Encoder فقط

(ب) Decoder فقط

(ج) Encoder و Decoder

(د) CNN

الحل:

(ج) Encoder و Decoder.

15. Self-Attention:

(أ) يعتمد على الصور

(ب) يربط الكلمات ببعضها

(ج) يحذف الكلمات

(د) يضغط النص

الحل:

(ب) يربط الكلمات ببعضها.

16. Positional Encoding يستخدم لـ:

(أ) حذف الترتيب

ب) تمثيل ترتيب الكلمات

ج) ضغط النص

د) حذف الكلمات

الحل:

ب) تمثيل ترتيب الكلمات.

17. Fine-tuning يعني:

أ) تدريب من الصفر

ب) تحسين نموذج جاهز

ج) حذف البيانات

د) ضغط النموذج

الحل:

ب) تحسين نموذج جاهز.

18. Transfer Learning:

أ) تدريب جديد

ب) نقل المعرفة

ج) حذف البيانات

د) تصنيف الصور

الحل:

ب) نقل المعرفة.

19. Zero-shot Learning:

أ) تدريب كامل

ب) بدون تدريب مباشر

ج) تعلم عميق

د) clustering

الحل:

ب) بدون تدريب مباشر.

20. Few-shot Learning:

أ) بيانات كثيرة

ب) بيانات قليلة

ج) بدون بيانات

د) ضغط البيانات

الحل:

ب) بيانات قليلة.

القسم الخامس: أسئلة نظرية متقدمة

1. اشرح Subword Tokenization ولماذا هي مهمة.

هي طريقة تقسيم الكلمات إلى أجزاء أصغر (Subwords) مثل:

playing → play + ing

أهميتها أنها تساعد في التعامل مع الكلمات النادرة أو غير المعروفة، وتقلل مشكلة الكلمات خارج القاموس (OOV).

2. ما الفرق بين Autoregressive Models و Masked Language Models؟

نماذج Autoregressive تتوقع الكلمة التالية بناءً على الكلمات السابقة.

أما Masked Language Models فتقوم بإخفاء كلمة داخل الجملة وتتوقعها اعتمادًا على السياق.

3. اشرح مفهوم Perplexity وكيف يتم استخدامه.

هو مقياس يستخدم لتقييم جودة النموذج اللغوي، ويقاس مدى قدرة النموذج على التنبؤ بالكلمات.

كلما كانت قيمة Perplexity أقل، كان النموذج أفضل.

4. ما الفرق بين BLEU و ROUGE بالتفصيل؟

BLEU يستخدم لتقييم الترجمة الآلية من خلال مقارنة النص المترجم بالنص المرجعي.

ROUGE يستخدم لتقييم التلخيص من خلال قياس التشابه بين النص الملخص والنص الأصلي.

5. اشرح بنية Transformer بالتفصيل.

يتكون من جزئين رئيسيين: Encoder و Decoder.

يعتمد على آلية Self-Attention التي تسمح للنموذج بفهم العلاقات بين الكلمات داخل الجملة.

يتميز بأنه يعالج البيانات بشكل متوازي مما يجعله أسرع وأكثر دقة من النماذج التقليدية.

6. ما هو Self-Attention وكيف يعمل؟

هو آلية تربط كل كلمة بباقي الكلمات في الجملة، حيث يتم حساب وزن (أهمية) لكل كلمة بالنسبة للكلمات الأخرى، مما يساعد النموذج على فهم السياق بشكل أفضل.

7. ما هي Positional Encoding ولماذا نحتاجها؟

هي طريقة لإضافة معلومات عن ترتيب الكلمات داخل الجملة، لأن نموذج Transformer لا يفهم الترتيب بشكل طبيعي.

تساعد النموذج على معرفة موقع كل كلمة.

8. اشرح الفرق بين Encoder و Decoder في Transformer.

Encoder مسؤول عن فهم النص وتحويله إلى تمثيل رقمي.

Decoder يستخدم هذا التمثيل لتوليد النص أو المخرجات.

9. ما هو Fine-tuning ولماذا هو مهم؟

هو عملية تعديل نموذج مدرب مسبقًا على بيانات جديدة خاصة بمهمة معينة.

أهميته أنه يوفر الوقت والجهد ويعطي نتائج أفضل.

10. ما هو Transfer Learning في NLP؟

هو استخدام نموذج تم تدريبه مسبقًا على مهمة معينة وتطبيقه على مهمة جديدة.

يساعد في تحسين الأداء خاصة عند قلة البيانات.

11. ما هو Zero-shot Learning مع مثال؟

هو قدرة النموذج على تنفيذ مهمة لم يتم تدريبه عليها مباشرة.

مثال: تصنيف نص إلى فئات بدون وجود بيانات تدريب لهذه الفئات.

12. ما الفرق بين GPT و BERT؟

GPT يستخدم لتوليد النصوص ويتوقع الكلمة التالية.

BERT يستخدم لفهم النص ويأخذ السياق من الجهتين (يمين ويسار).

13. اشرح Seq2Seq Model مع مثال.

هو نموذج يحول نص إلى نص آخر.

مثال: ترجمة جملة من العربية إلى الإنجليزية.

14. ما هي التحديات في بناء Chatbot؟

فهم اللغة الطبيعية، التعامل مع السياق، اختلاف طريقة كتابة المستخدمين، والتعامل مع الأخطاء اللغوية.

15. كيف تقيم نموذج NLP؟ (metrics)

يتم التقييم باستخدام مقاييس مثل:

Accuracy، Precision، Recall، و F1-score.

القسم السادس: أسئلة عملية / تصميم أنظمة

1. لديك نص طويل: كيف تقوم بتلخيصه باستخدام NLP؟

يتم استخدام نماذج التلخيص مثل Transformer، إما بطريقة Extractive (اختيار أهم الجمل) أو Abstractive (إعادة صياغة النص)

المرحلة الأولى: المعالجة الذكية للمدخلات (Smart Ingestion)

النصوص الطويلة تتجاوز قدرة ذاكرة النماذج (Context Window). الحل هو:

Text Splitting: تقسيم النص إلى أجزاء (Chunks) بحجم 1000 كلمة لكل جزء.

Overlap: ترك تداخل بسيط (مثلاً 100 كلمة) بين الأجزاء لضمان عدم ضياع سياق الجمل المقطوعة في المنتصف.

المرحلة الثانية: اختيار استراتيجيات التلخيص (Execution Strategies)

هناك 3 طرق هندسية عالمية، وأفضلها للتقارير الطويلة هي الثالثة:

1. طريقة الحشو (Stuffing):

كيف: وضع النص كله في البرومبت (Prompt) وطلب التلخيص.

متى: للنصوص القصيرة فقط (مقال واحد).

2. طريقة الخريطة والتقليص (Map-Reduce):

Map: تلخيص كل جزء (Chunk) بشكل مستقل.

Reduce: جمع كل الملخصات الصغيرة وتلخيصها في ملخص نهائي واحد.

الميزة: سريعة جداً لأنها تدعم المعالجة المتوازية (Parallel Processing).

3. طريقة الصقل المتتابع (Refine) - "الأذكى":

يتم تلخيص الجزء الأول.

عند تلخيص الجزء الثاني، يتم إعطاء النموذج (الملخص السابق + الجزء الجديد) ليقوم بدمجهما.

الميزة: الملخص النهائي يكون مترابطاً جداً وكأنه قصة واحدة وليس نقاطاً مبعثرة.

المرحلة الثالثة: الكود البرمجي التنفيذي (Python Implementation)

سنستخدم مكتبة LangChain مع نموذج GPT-4o لتنفيذ استراتيجية Refine لأنها الأقوى للنصوص العربية الطويلة..

المرحلة الرابعة: لمسات "القوة" الاحترافية (Pro Touches)

لجعل النظام "حالياً وقوياً" كما طلبت، نضيف الطبقات التالية:

Custom Prompt (التلخيص الموجه):

بدلاً من "لخص"، نطلب من النموذج: "استخرج أهم 5 قرارات مالية، التواريخ المذكورة، وأسماء الشخصيات الرئيسية". هذا يحول الملخص من نص إنشائي إلى بيانات استخباراتية.

استخدام نظام NER (الذي شرحناه سابقاً) داخل التلخيص للتأكد من أن الأسماء العربية (مثل: "صالح بن أحمد") لم يتم تشويها أثناء التلخيص.

:Fact Checking Layer

مقارنة الملخص النهائي بالنص الأصلي للتأكد من أن الأرقام (مثل: 50 مليون دولار) لم تتغير إلى (5 مليون) بسبب خطأ في التوليد.

الخلاصة:

التلخيص الذكي = تقسيم ذكي + استراتيجية Refine + تحقق من الحقائق.

2. صمّم نظام ترجمة آلية بسيط.

1. المعمارية الأساسية: المشفر وفك التشفير (Encoder-Decoder)

يعتمد النظام على هيكلية Transformer (وهي التقنية التي بني عليها ChatGPT). يتكون النظام من جزأين:

المُشفّر (Encoder): يقرأ الجملة المصدر (مثلاً بالعربي) ويحولها إلى "تمثيل رقمي" يفهم المعنى والسياق.

فك التشفير (Decoder): يأخذ هذا التمثيل الرقمي ويبدأ بتوليد الكلمات باللغة الهدف (مثلاً بالإنجليزي) كلمة بكلمة.

2. المسار التقني لبناء النظام (The Pipeline)

أ. جمع البيانات (Parallel Corpus)

الترجمة تحتاج لبيانات ضخمة "متوازية"، أي جملة بالعربي وما يقابلها بالإنجليزي.

المصادر: بيانات الأمم المتحدة، مجمع "أوبوس" (OPUS)، أو ترجمات الأفلام.

التنسيق: ملفين نصيين، كل سطر في الملف الأول ترجمة للسطر في الملف الثاني.

ب. المعالجة الأولية (Preprocessing)

Subword Tokenization: بدلاً من ترجمة الكلمة كاملة، نقسمها لأجزاء (مثلاً: "سياراتنا" تصبح "سيارات" + "نا"). هذا يساعد النظام على ترجمة كلمات لم يراها من قبل.

التبديل اللغوي: إضافة علامات مثل <sos> (بداية الجملة) و <eos> (نهاية الجملة).

ج. التدريب (Training)

نستخدم نموذجاً مدرباً مسبقاً (Pre-trained) ونقوم بعمل Fine-tuning له ليكون متخصصاً:

نماذج مقترحة: Helsinki-NLP/opus-mt-ar-en أو نموذج mBART.

3. تطبيق برمجى بسيط (Python Code)

باستخدام مكتبة Transformers من HuggingFace، يمكنك بناء المترجم في ثوانٍ.

4. كيف تبني Chatbot ذكي؟

1. الهيكل المعماري للبوت الذكي (Agentic Architecture)

البوت الاحترافي يتكون من 4 مكونات رئيسية تعمل معاً في أجزاء من الثانية:

أ. العقل المدبر (The LLM Brain)

الاعتماد على نماذج قوية مثل GPT-4o أو Claude 3.5 أو نماذج مفتوحة المصدر مثل Llama 3.

هذا الجزء مسؤول عن فهم القصد (Intent) وتوليد الرد الطبيعي.

ب. الذاكرة (Memory System)

البوت "الغبى" ينسى ما قلته قبل دقيقة. البوت "الذكي" يمتلك نوعين من الذاكرة:

Short-term: لتذكر سياق المحادثة الحالية (Chat History).

Long-term: لتذكر تفاصيل العميل من محادثات جرت قبل أسابيع (باستخدام Vector DB).

ج. الأدوات والوظائف (Tools/Function Calling)

هذا هو الفرق بين بوت "يتكلم" وبوت "يفعل". البوت الذكي يرتبط بـ APIs للقيام بمهام:

"تحقق من رصيدي" -> يستدعي دالة get_balance().

"احجز لي موعد" -> يستدعي دالة book_appointment().

د. المخطط (The Orchestrator)

استخدام إطارات عمل مثل LangGraph أو CrewAI لإدارة تدفق الأفكار والتأكد من أن البوت يفكر قبل أن يجيب (Chain of Thought).

2. المسار التقني للتنفيذ (The Technical Pipeline)

الخطوة 1: هندسة الأوامر (System Prompt Engineering)

تحديد "شخصية" البوت وقيوده. مثال:

"أنت المساعد الذكي لبنك (X). لغتك مزيج بين الفصحى واللهجة اليمنية المهدبة. لا تطلب أبداً كلمة السر من العميل. إذا لم تعرف الإجابة، وجه العميل للاتصال بالرقم 800..."

الخطوة 2: ربط المعرفة (RAG Integration)

بدلاً من تدريب النموذج على بياناتك (وهو أمر مكلف)، نستخدم الـ RAG لجعله يقرأ ملفات الشركة (PDFs, Excel) لحظياً ويجيب منها بدقة 100%.

الخطوة 3: معالجة الصوت واللغة (Speech & Text)

STT: تحويل صوت العميل (حتى بالعامية) إلى نص.

TTS: تحويل رد البوت لنص مسموع طبيعي (مثل ElevenLabs).

6. كيف تتعامل مع Out-of-Vocabulary words؟

باستخدام Subword Tokenization أو نماذج Embedding التي تتعامل مع أجزاء الكلمات.

7. لديك Dataset غير متوازن: كيف تعالجه؟

باستخدام تقنيات مثل Oversampling أو Undersampling لتحقيق التوازن.

8. كيف تبني نظام NER باستخدام Deep Learning؟

1. ما هو الـ NER وماذا يستخرج؟

النظام يقوم بتصنيف كل كلمة (Token) في النص إلى فئات محددة:

ORG: مؤسسات (مثل: بنك اليمن الدولي).

PER: أشخاص (مثل: أحمد).

LOC: مواقع جغرافية (مثل: صنعاء).

DATE: تواريخ وعمليات.

2. الهيكل الهندسي للنظام (Deep Learning Architecture)

للحصول على أفضل أداء، نستخدم بنية Bi-LSTM + CRF أو Fine-tuned BERT.

المرحلة الأولى: تمثيل الكلمات (Embedding Layer)

نستخدم Embeddings قوية مثل Arabic-BERT أو RoBERTa. هذه الطبقة تحول الكلمة إلى متجهات رياضية تفهم السياق (مثلاً: تفهم أن كلمة "علي" في "سلمت على علي" هي اسم شخص، بينما "علي" في "عليّ الواجب" هي حرف جر وصفة).

المرحلة الثانية: الطبقة السياقية (Bi-LSTM / Transformer Layer)

تسمح للنموذج بقراءة الجملة من اليمين إلى اليسار ومن اليسار إلى اليمين (Bidirectional).

هذا يساعد في فهم أن الكلمة التي تأتي بعد "شركة" غالباً ما تكون ORG.

المرحلة الثالثة: طبقة القرار (CRF Layer - Conditional Random Fields)

هذه هي الطبقة "الذكية" التي تضمن منطقية المخرجات. هي تمنع النموذج من ارتكاب أخطاء غبية، مثل أن يقول أن الكلمة الأولى هي "بداية اسم شخص" والكلمة الثانية هي "نهاية اسم منظمة".

3. خطوات بناء النظام برمجياً (Implementation Steps)

الخطوة 1: تجهيز البيانات بنظام BIO Tagging

يجب تسمية البيانات يدوياً أو استخدام بيانات جاهزة بهذا التنسيق:

B-PER: بداية اسم الشخص.

I-PER: داخل اسم الشخص (إذا كان الاسم مركباً).

O: كلمة عادية (Outside).

التحديات في اللغة العربية وكيف نحلها؟

التشكيل (Diacritics): الكلمات قد يتغير معناها بتغير التشكيل. الحل: استخدام Pre-trained models تدربت على نصوص مشكولة وغير مشكولة.

الزوائد (Affixes): مثل "وبالشركات" (و + ب + ال + شركات). الحل: استخدام Sub-word Tokenization (مثل WordPiece) الذي يفك الكلمة لأجزائها الأصلية.

الغموض: كلمة "مصر" قد تكون دولة (LOC) أو اسم شخص (PER). الحل: نماذج ال Transformers التي تعتمد على ال Attention Mechanism لحل الغموض بناءً على الكلمات المحيطة.

5. كيف تجعل النظام "قوياً" في بيئة العمل؟

Active Learning: عندما يخطئ النظام في تصنيف اسم شركة جديدة، يقوم موظف بشري بتصحيحها، ويعيد النظام تعلمها فوراً.

Ensemble Method: دمج نتائج نموذج BERT مع "قواعد بيانات" (Gazetteers) تحتوي على أسماء المدن والشركات المعروفة لضمان دقة 100% في الأسماء المشهورة.

Speed Optimization: تحويل النموذج إلى صيغة ONNX ليعمل بسرعة فائقة في الخادم (Server).

9. كيف تستخدم Transformer في مشروعك؟

يمكن استخدامه في مهام متعددة مثل الترجمة، التلخيص، التصنيف، وتحليل المشاعر.

10. كيف تختار بين BERT و GPT حسب المهمة؟

BERT يستخدم لمهام الفهم مثل التصنيف و NER.

GPT يستخدم لمهام التوليد مثل كتابة النصوص.

11. لديك نصوص noisy: كيف تنظفها؟ (advanced)

باستخدام Regex، Normalization، إزالة الرموز، وتصحيح الأخطاء الإملائية.

12. كيف تحسن سرعة inference لنموذج NLP؟

باستخدام تقنيات مثل Quantization و Model Distillation لتقليل حجم النموذج.

13. صمّم نظام Question Answering.

هناك نوعين للنظم الذكية حالياً:

Extractive QA (الاستخراجي): يبحث عن الإجابة "نصاً" داخل الوثيقة ويحدد مكانها (مثل نماذج BERT).

Generative QA (التوليدي): يقرأ عدة وثائق، يستوعبها، ثم يكتب إجابة كاملة بأسلوبه الخاص (مثل GPT-4o أو Claude 3).

2. المخطط الهندسي للنظام (Architecture Pipeline)

يتكون النظام من ثلاث طبقات مترابطة:

أ. طبقة الاسترجاع الذكي (The Retriever)

عندما يطرح المستخدم سؤالاً، لا يذهب النظام للبحث في كل الكتب، بل يستخدم Semantic Search:

Query Expansion: إذا كان السؤال غامضاً، يقوم النظام بإعادة صياغته ليكون أوضح (مثلاً: تحويل "كيف أفتح حساب؟" إلى "إجراءات فتح حساب بنكي للأفراد في اليمن").

Vector Search: البحث في قاعدة البيانات المتجهة (Vector DB) لجلب أفضل 3 أو 5 فقرات ذات صلة.

ب. طبقة القراءة والتحليل (The Reader/Reranker)

Reranking: بعد جلب الفقرات، يتم ترتيبها مرة أخرى باستخدام نموذج (Cross-Encoder) للتأكد من أن الفقرة الأولى هي التي تحتوي على الإجابة فعلاً.

Context Loading: وضع هذه الفقرات داخل "سياق" النموذج اللغوي الضخم (LLM).

ج. طبقة التوليد والتحقق (The Generator & Verifier)

Response Generation: صياغة الإجابة بلغة العميل (عربي/إنجليزي).

Citations (المصادر): النظام القوي هو الذي يقول لك: "الإجابة هي كذا.. بناءً على الفقرة رقم 2 في وثيقة سياسة البنك".

3. الميزات "الذكية" التي تجعل النظام قوياً (Pro Features).

. التطبيق العملي (Technical Implementation)

استخدام مكتبة Haystack أو LangChain هو الخيار

5. كيف تجعل النظام "عالمياً" (Global Scale)؟

دعم اللهجات: إضافة طبقة Translation أو استخدام نماذج Multilingual قوية تفهم أن "أشتي" (يمني) هي نفسها "أريد" (فصحى).

السرعة: استخدام تقنية Quantization لتقليل حجم النماذج لتعمل بسرعة استجابة أقل من 1 ثانية.

الأمان: تشفير البيانات المسترجعة بحيث لا يطلع عليها حتى مطور النظام (Privacy-Preserving QA).

14. كيف تبني نظام Text Summarization؟

1. اختيار المنهجية (Summarization Paradigms)

هناك طريقتان أساسيتان، والنظام الذكي هو الذي يدمج بينهما:

التلخيص الاستخراجي (Extractive): يعمل مثل "القلم الفسفوري"، حيث يحدد الجمل الأهم من النص الأصلي ويجمعها. (سريع، دقيق، لكنه قد يفتقر للترابط).

التلخيص التجريدي (Abstractive): يعمل مثل "العقل البشري"، يقرأ النص ثم يعيد صياغته بكلمات جديدة تماماً. (سلس، طبيعي، لكنه يحتاج رقابة لمنع الهلوسة).

2. المخطط الهندسي للنظام (The System Architecture)

المرحلة الأولى: هندسة المدخلات (The Context Window Management)

تكمّن المشكلة الكبرى في النصوص الطويلة جداً (مثل تقارير البنوك السنوية). الحل الذكي هو استخدام تقنية Map-Reduce:

Map: تقسيم النص الطويل إلى أجزاء (Chunks) وتلخيص كل جزء على حدة.

Collapse: دمج التلخيصات الأولية.

Reduce: تلخيص التلخيص للوصول إلى النتيجة النهائية المركزة.

المرحلة الثانية: محرك المعالجة (The Intelligence Core)

بدلاً من استخدام نموذج لغوي واحد، نستخدم نظام Refinement Loop:

Initial Summary: توليد مسودة أولى.

Critique: نموذج آخر (أو نفس النموذج) يقوم بمراجعة الملخص: "هل أغفلت تاريخاً معيناً؟ هل هناك معلومة مالية خاطئة؟".

Final Polish: صياغة النسخة النهائية بناءً على الملاحظات.

3. الميزات العميقة للنظام (Smart Features)

التلخيص المشروط (Controllable Summarization): إمكانية تحديد "منظور" التلخيص. مثال: "لخص هذا العقد القانوني من وجهة نظر (المخاطر المادية) فقط".

دعم اللغات المتقاطعة (Cross-Lingual): إدخال نص باللغة الإنجليزية والحصول على التلخيص فوراً باللغة العربية بلهجة احترافية.

التلخيص بالنقاط الذكية (Structured Output): عدم الاكتفاء بفقرة، بل تنظيم المخرجات إلى (أهم القرارات، التواريخ الرئيسية، المسؤوليات).

4. التقييم التقني (Evaluation Metrics)

كيف نعرف أن التلخيص "حالي" وذكي؟ لا نعتمد على البشر فقط، بل نستخدم:

ROUGE Score: لقياس مدى تشابه الكلمات بين ملخص النظام وملخص البشر.

BERTScore: لقياس التشابه في "المعنى" وليس فقط الكلمات.

FactCC: نموذج ذكاء اصطناعي وظيفته الوحيدة التأكد من أن الملخص لم ي اخترع معلومات غير موجودة في الأصل (Fact-checking).

15. صمّم نظام NLP متكامل لشركة (مثلاً بنك أو خدمة عملاء).

يتضمن: جمع بيانات العملاء، تحليل النصوص، تصنيف الطلبات، chatbot للردود، ونظام تقارير لتحسين الخدمة.

نظام NLP متكامل للبنوك

(LLMs + RAG Architecture)

1. هيكلية النظام

System Architecture Overview

النظام ليس مجرد Chatbot، بل منظومة ذكاء اصطناعي متكاملة تتكون من أربع طبقات رئيسية:

أ. طبقة استقبال البيانات

Ingestion Layer

في هذه المرحلة يتم جمع كل مصادر المعرفة الخاصة بالبنك:

بيانات غير مهيكلة (Unstructured):

ملفات PDF مثل:

سياسات القروض

شروط فتح الحسابات

بيانات مهيكلة (Structured):

سجلات العمليات المالية

قواعد بيانات البنك

اللغات:

دعم اللغة العربية (الفصحى + العامية)

دعم اللغة الإنجليزية

ب. محرك البحث الذكي

Vector Database - RAG

لمنع أخطاء النموذج (Hallucination)، يتم استخدام تقنية RAG:

تحويل جميع وثائق البنك إلى Embeddings (متجهات رقمية)

باستخدام نماذج مثل:

Cohere

OpenAI Ada

تخزين هذه المتجهات في قواعد بيانات مثل:

Pinecone

Milvus

عند سؤال العميل:

→ يقوم النظام أولاً بالبحث عن المعلومة الدقيقة داخل الوثائق

→ ثم يستخدمها للإجابة

2. المسار التقني لمعالجة الطلب

Pipeline Flow

المرحلة الأولى: الفهم والاستيعاب

NLU (Natural Language Understanding)

مثال:

"أشتي أعرف كم الفائدة على قرض السيارة؟"

:Language Detection

تحديد اللغة (عربي / إنجليزي) + اللهجة

:Intent Recognition

تحديد نية المستخدم (استفسار عن القروض)

:Entity Extraction

استخراج الكيانات مثل:

المنتج: سيارة

العملية: فائدة

المرحلة الثانية: المعالجة والتوليد

Processing & Generation

:Prompt Engineering

إرسال سؤال العميل + المعلومات المسترجعة من RAG

إلى نموذج لغوي ضخم مثل:

GPT-4o

Llama 3

Guardrails (حواجز الحماية):

نظام أمان يضمن أن:

لا يتم إعطاء نصائح مالية غير قانونية

لا يتم توليد محتوى غير مناسب

المرحلة الثالثة: الإخراج

Response Generation

تحويل الرد إلى:

نص طبيعي

أسلوب ودود

مناسب لهجة العميل

3. الميزات المتقدمة للنظام

The "Pro" Features

(تكملة طبيعية للنظام المتكامل)

دعم متعدد اللغات واللهجات (Arabic Dialects Support)

تخصيص الردود حسب نوع العميل (Personalization)

التكامل مع أنظمة البنك الداخلية (Core Banking Integration)

سجل محادثات لتحليل تجربة المستخدم (Conversation Logging)

التعلم المستمر من تفاعل المستخدم (Continuous Learning)

نظام أمان متقدم لحماية البيانات (Security & Compliance)

4. دورة حياة التطوير والنشر (MLOps)

التطوير (Development): استخدام Python مع إطارات عمل مثل LangChain أو LlamaIndex.

التقييم (Evaluation): استخدام إطار عمل Ragas لتقييم دقة الإجابات البنكية.

النشر (Deployment): رفع النظام على Docker Containers داخل سحابة خاصة (Private Cloud) لضمان خصوصية بيانات العملاء.

المراقبة (Monitoring): استخدام أدوات مثل LangSmith لمراقبة جودة المحادثات وتكلفتها